

# Relatório de Atividade - Estimação de parâmetros

Débora Nunes Pinto de Oliveira

Prof. Antonio Marcus, Estimação e Identificação de Sistemas 21.2

16 de agosto de 2021

Esse documento tem por objetivo descrever a identificação de modelos pelo método dos mínimos quadrados. Esse algoritmo determina uma estimação dos parâmetros de um modelo e é adequado para **processos não-lineares ou variantes no tempo**.

Sumário

[Fundamentação teórica](#)

[Desenvolvimento, resultados e discussão](#)

[Referências bibliográficas](#)

## Fundamentação teórica

Com base em dados coletados, é possível identificar um modelo cujo comportamento é semelhante à um planta qualquer observada. Entretanto, é importante destacar que esse modelo deve ser anteriormente validado, uma vez que os dados coletados podem representar apenas um ponto de operação específico. Além disso, é importante garantir que os dados coletados sejam representativos, isto é, que o experimento realizado explore corretamente os valores reais de entrada da planta.

Nesse documento, serão identificados sistemas dinâmicos, isto é, plantas cuja saída atual dependem dos valores de entrada atual e de entrada e saída anteriores. Dessa forma, a saída  $y(t)$  do processo pode ser representada como:

$$y(t) + a_1 y(t-1) + \dots + a_n y(t-n) = b_1 u(t-1) + \dots + b_m u(t-m)$$

O tempo de amostragem é considerado unitário, e os sistemas analisados serão sistemas discretos. A saída estimada do processo  $\hat{y}(t)$  pode ser representado compactamente por:

$$\hat{y}(t) = -a_1 y(t-1) - \dots - a_n y(t-n) + b_1 u(t-1) + \dots + b_m u(t-m) = \varphi^T(t) \theta$$

para  $\varphi(t) = [-y(t-1) \dots -y(t-n) \ u(t-1) \dots u(t-m)]^T$  e  $\theta = [a_1 \dots a_n \ b_1 \dots b_m]^T$ . É evidente que o modelo sugerido para a identificação é linear. Dessa forma, a escolha de  $\theta$  para que a diferença entre a saída estimada  $\hat{y}(t)$  e real  $y(t)$  seja nula é calculada conforme uma função de custo  $V(\theta, t)$ , que, para o método dos mínimos quadrados, é definida como o erro quadrático médio do valor real medido e o estimado em  $N$  amostras coletadas:

$$V(\theta, t) = \frac{1}{N} \sum_{t=1}^N [y(t) - \hat{y}(t)]^2 = \frac{1}{N} \sum_{t=1}^N [y(t) - \varphi^T(t) \theta]^2$$

Para encontrar  $\hat{\theta} = \arg \min_{\theta} V(\theta, t)$ , encontra-se  $\hat{\theta}$  tal que  $\partial V(\theta, t) / \partial \theta = 0$ :

$$\begin{aligned} \sum_{t=1}^N \varphi(t) [y(t) - \varphi^T(t) \hat{\theta}] &= 0 \rightarrow \sum_{t=1}^N \varphi(t) y(t) = \sum_{t=1}^N \varphi(t) \varphi^T(t) \hat{\theta} \\ \therefore \hat{\theta} &= \left[ \sum_{t=1}^N \varphi(t) \varphi^T(t) \right]^{-1} \sum_{t=1}^N \varphi(t) y(t) = P(t) \sum_{t=1}^N \varphi(t) y(t) \end{aligned}$$

Logo, é evidente que  $P(t)$  deve ser inversível. Se considerarmos que há um ruído branco de média nula  $e(t)$  na saída  $y(t)$ , é possível considerar esse erro na modelagem ao reescrever a equação de estimação como:

$$\hat{y}(t) = \varphi^T(t) \theta_0 + e(t)$$

Logo, encontra-se que:

$$\hat{\theta}_0 = P(t) \sum_{t=1}^N \varphi(t) [y(t) + e(t)]$$

Sendo assim, o erro entre a estimativa  $\hat{\theta}$  não considerando o erro na modelagem e  $\theta_0$  considerando o erro na modelagem é dado por:

$$\tilde{\theta} = \hat{\theta} - \theta_0 = P(t) \sum_{t=1}^N \varphi(t) e(t)$$

A esperança desse erro é então dado por:

$$E(\tilde{\theta}) = P(t) \sum_{t=1}^N \varphi(t) E(e(t)) = 0$$

Logo, é possível concluir que a estimativa por mínimos quadrados para modelos com ruído branco na medição não possui viés.

## Desenvolvimento, resultados e discussão

Com o intuito de verificar o processo de identificação de uma planta desconhecida pelo método dos mínimos quadrados, serão simulados dois modelos discretos  $\delta_1$  e  $\delta_2$ . Ambos equacionamentos consideram o erro com distribuição normal  $e(t)$  na modelagem. A função de transferência para  $\delta_1$  e  $\delta_2$  são, respectivamente:

$$\delta_1 : Y = \frac{q^{-1}}{1 - 0.8q^{-1}} U + \frac{q^{-1}}{1 - 0.8q^{-1}} E$$

$$\delta_2 : Y = \frac{q^{-1}}{1 - 0.8q^{-1}} U + E$$


para  $u(t)$  e  $e(t)$  a entrada e erro, respectivamente. Ao transformar as funções de transferência dos sistemas  $\delta_1$  e  $\delta_2$  para o domínio do tempo, obtém-se:

$$\delta_1 : y(t) = 0.8y(t-1) + u(t-1) + e(t-1)$$

$$\delta_2 : y(t) = 0.8y(t-1) + u(t-1) + e(t) - 0.8e(t-1)$$

Para os experimentos realizados, foi considerado que tanto  $u(t)$  como  $e(t)$  são variáveis aleatórias de distribuição normal com média nula e variância unitária, ou seja,  $u \sim N(0, 1)$  e  $e \sim N(0, 1)$ . Para  $N = 200$  amostras, é possível gerar os sinais de entrada  $u(t)$  e  $e(t)$  e de saída  $y_1(t)$  e  $y_2(t)$  para cada dos modelos  $\delta_1$  e  $\delta_2$  conforme ilustrado na [Figura 1](#).

inputGen



**Figura 1:** Sinais de entrada  $u(t)$  e  $e(t)$  e de saída  $y_1(t)$  e  $y_2(t)$  dos modelos  $\delta_1$  e  $\delta_2$ , respectivamente.


Em seguida, os parâmetros da função de transferência  $H(q) = Y(q)/U(q)$  foram estimados utilizando o método dos mínimos quadrados descrito na seção anterior. Para os modelos  $\delta_1$  e  $\delta_2$ , considerou-se um sistema parametrizado por duas constantes  $a$  e  $b$  conforme a função de transferência  $H(q^{-1})$ :

$$H(q^{-1}) = \frac{bq^{-1}}{1 + aq^{-1}}$$

Os parâmetros  $\hat{a}$  e  $\hat{b}$  estimados em função do tempo estão ilustrados na [Figura 2](#).

Warning: Matrix is close to singular or badly scaled. Results may be inaccurate. RCOND = 1.487760e-17.

Warning: Matrix is close to singular or badly scaled. Results may be inaccurate. RCOND = 1.358781e-17.



**Figura 2:** Parâmetros estimados  $\hat{a}$  e  $\hat{b}$  para os modelos simulados  $\delta_1$  e  $\delta_2$ , respectivamente.

Observando a [Figura 2](#), é evidente que os parâmetros estimados convergem para o valor real apenas para o modelo  $\delta_1$ .

Além disso, é claro que  $\delta_1$  depende unicamente dos valores de erro  $e(t-1)$  no instante anterior, enquanto o modelo  $\delta_2$  é influenciado pelo termo da amostra atual  $e(t)$  e anterior  $e(t-1)$ . A covariância do sinal  $z(t) = e(t) - 0.8e(t-1)$  é dada por:

$$\text{Cov}[z(t), z(t-j)] = \text{Cov}[e(t), e(t-j)] - 0.8\text{Cov}[e(t-1), e(t-1-j)] - 0.8\text{Cov}[e(t-1), e(t-j)] + 0.64\text{Cov}[e(t), e(t-1-j)]$$

Como  $e(t)$  e  $e(t-1)$  possuem distribuição normal, é evidente que  $\text{Cov}[e(t), e(t-j)] = \text{Cov}[e(t-1), e(t-1-j)] = 0$  para  $j \neq 0$ . Logo, tem-se que para  $j \neq 0$ :


$$\text{Cov}[z(t), z(t-j)] = -0.8\text{Cov}[e(t-1), e(t-j)] + 0.64\text{Cov}[e(t), e(t-1-j)]$$

Para  $z(t)$  ser um ruído gaussiano, a covariância desse sinal deve ser nula para qualquer  $j \neq 0$ . Entretanto, para  $j = 1$ , a expressão resulta em:

$$\text{Cov}[z(t), z(t-1)] = -0.8\text{Cov}[e(t-1), e(t-1)] = -0.8\lambda^2$$

considerando  $\lambda$  a variância do erro  $e(t)$ . Analogamente, o resultado encontrado para  $j = -1$  é

$\text{Cov}[z(t), z(t-1)] = 0.64\lambda^2$ . Dessa forma, o sinal  $z(t)$  não é um ruído gaussiano. Observando a [Figura 3](#), que ilustra a densidade espectral de potência dos sinais  $u(t)$ ,  $e(t)$  e  $z(t)$ , é evidente que o comportamento da soma  $e(t) + e(t-1)$  difere dos ruídos brancos  $u(t)$  e  $e(t)$ : teoricamente, é definido que a densidade espectral de potência de uma distribuição normal oscila em torno de uma constante, enquanto a DEP da soma de ruídos decai com o aumento da frequência. Dessa forma, é confirmado que o sinal  $z(t)$  de entrada do modelo  $\delta_2$  não é um ruído gaussiano.



**Figura 3:** Densidade espectral de potência dos sinais  $u(t)$ ,  $e(t)$  e  $z(t)$ .

Em seguida, a covariância para o modelo  $\delta_2$  do erro  $\tilde{\theta} = \hat{\theta} - \hat{\theta}_0 = P(t) \sum_{i=1}^N \varphi(t) [e(t) - 0.8e(t-1)]$  é dada como:

$$\begin{aligned}
 R = E(\tilde{\theta}\tilde{\theta}^T) &= E \left[ P(t) \sum_{t,s=1}^N \varphi(t) [e(t) - 0.8e(t-1)] [e(s) - 0.8e(s-1)] \varphi^T(s) P(s) \right] \\
 &= P(t) \sum_{t,s=1}^N \varphi(t) \varphi^T(s) P(s) E \left\{ [e(t) - 0.8e(t-1)] [e(s) - 0.8e(s-1)] \right\} \\
 &= P(t) \sum_{t,s=1}^N \varphi(t) \varphi^T(s) P(s) \left( E[e(t)e(s)] - 0.8E[e(t)e(s-1)] - 0.8E[e(t-1)e(s)] + 0.64E[e(t-1)e(s-1)] \right)
 \end{aligned}$$

Sabendo que  $E(XY) = \text{Cov}(X, Y) + E(X)E(Y)$  para variáveis aleatórias  $X$  e  $Y$ , tem-se que:

- Como  $e(t)$  e  $e(t-1)$  são ruídos gaussianos de média nula, logo  $E[e(t)e(s)] = E[e(t-1)e(s-1)] = \lambda^2 \delta(0)$ .
- No entanto,  $E[e(t-1)e(s)] = \text{Cov}[e(t-1)e(s)] = \lambda^2, \forall (t-1) = s$ . Considerando que há  $N$  amostras, esse resultado equivale à  $N-1$  impulsos de magnitude  $\sigma^2$ .
- Analogamente,  $E[e(t)e(s-1)] = \text{Cov}[e(t)e(s-1)] = \lambda^2, \forall (t) = s-1$ . Considerando que há  $N$  amostras, esse resultado equivale à  $N-1$  impulsos de magnitude  $\sigma^2$ .

Logo, considerando que a esperança está dentro de um somatório, obtém-se que:

$$\begin{aligned}
 R &= P(t) \sum_{t,s=1}^N \varphi(t) \varphi^T(s) P(s) \left( E[e(t)e(s)] - 0.8E[e(t)e(s-1)] - 0.8E[e(t-1)e(s)] + 0.64E[e(t-1)e(s-1)] \right) \\
 &= P(t) \lambda^2 [1.64 - 1.6(N-1)] \sum_{t,s=1}^N \varphi(t) \varphi^T(s) P(s) = P(t) \lambda^2 (3.24 - 1.6N)
 \end{aligned}$$

Considerando que a covariância da entrada é denominada  $M = \lim_{N \rightarrow \infty} \frac{1}{N} P^{-1}(t)$ , é possível reescrever a covariância do erro como  $R = 2\lambda^2 M^{-1}$ . Logo:

$$\lim_{N \rightarrow \infty} R = M^{-1} \lambda^2 (3.24N^{-1} - 1.6)$$

Logo,  $R$  depende do número de amostras coletadas e decai conforme o aumento de  $N$ . Entretanto, o valor mínimo de  $R \neq 0$  e é equivalente à  $-1.6M^{-1}\lambda^2$ . Dessa forma, a estimativa dos parâmetros por mínimos quadrados não é capaz de rejeitar o erro provocado pelo ruído  $z(t) = e(t) - 0.8e(t-1)$ . Conforme apresentado na bibliografia [1], esse resultado difere para o ruído gaussiano  $e(t)$ , já que, nesse caso,  $R = \frac{\lambda^2}{N} M^{-1}$  e a covariância do erro tende a 0 ao passo que  $N \rightarrow \infty$ .

## Referências bibliográficas

[1] L. LJUNG. **System Identification: Theory for the User**. Pearson, 1998. 2nd edition, ISBN 9788131744956.