

Relatório de Atividade 07 - Métodos de estimação paramétricos

Débora Nunes Pinto de Oliveira

Prof. Antonio Marcus, Estimação e Identificação de Sistemas 21.2

21 de setembro de 2021

Esse documento tem por objetivo descrever estimação dos parâmetros de um modelo identificado conforme um modelo paramétrico.

Table of Contents

[Introdução](#)

[Estimando os parâmetros do modelo por mínimos quadrados](#)

[Regressão linear com mínimos quadrados](#)

[Análise da polarização da estimativa](#)

[Análise probabilística](#)

[Análise de correlação do erro do preditor com dados anteriores](#)

[Desenvolvimento](#)

[Resultados e discussão](#)

[Referências bibliográficas](#)

Introdução

A partir da metodologia reportada nas últimas atividades, temos disponível uma família de modelos para parametrizar uma planta desconhecida. Nesse estudo, será considerada o processo genérico modelado por:

$$y(t) = G(q, \theta)u(t) + H(q, \theta)e(t)$$

para $y(t)$ o sinal de saída, $u(t)$ o sinal de entrada e $e(t)$ um ruído branco. Conforme descrito na Atividade 4, para um vetor de parâmetros estimados θ , é possível escrever a equação genérica do preditor como:

$$\hat{y}(t|\theta) = W_y(q, \theta)y(t) + W_u(q, \theta)u(t), \text{ para } W_y(q, \theta) = [1 - H^{-1}(q, \theta)] \text{ e } W_u(q, \theta) = H^{-1}(q, \theta)G(q, \theta)$$

Nesse relatório, o objetivo é, a partir do conjunto de dados Z amostrados do processo, construir uma estimativa adequada de θ . A qualidade dessa estimativa é dada pela minimização do erro de predição:

$$\varepsilon(t, \theta) = y(t) - \hat{y}(t, \theta) = H^{-1}(q, \theta)[y(t) - G(q, \theta)u(t)]$$

O critério de limite para esse problema de otimização pode ser um escalar ou probabilístico.

Estimando os parâmetros do modelo por mínimos quadrados

Inicialmente, será avaliado um método para determinar o "quão grande" é o erro de predição $\varepsilon(t, \theta)$. Considerando $L(q)$ um filtro linear estável, é definido o sinal de erro filtrado:

$$\varepsilon_F(t, \theta) = L(q)\varepsilon(t, \theta) = [L^{-1}(q)H(q, \theta)]^{-1}[y(t) - G(q, \theta)u(t)]$$

tal que a função de custo é dada por:

$$V(\theta, Z) = \frac{1}{N} \sum_{t=1}^N \ell(\varepsilon_F(t, \theta))$$

para $\ell(\cdot)$ um valor escalar positivo. O objetivo do filtro $L(q)$ é permitir flexibilidade para considerar (ou desconsiderar) propriedades momentâneas do erro de predição, tais como remoção de alta frequências desnecessários na modelagem do problema. Essa transformação de $\varepsilon(t, \theta)$ para $\varepsilon_F(t, \theta)$ é equivalente a transformar o modelo do ruído de $H(q, \theta)$ para $\bar{H}_L(q, \theta) = L^{-1}(q)H(q, \theta)$. Nesse estudo, será considerado $L(q)$ um polinômio mônico e unitário.

Dessa forma, a estimativa $\hat{\theta}$ é encontrada como o mínimo local da função de custo:

$$\hat{\theta} = \arg \min V(\theta, Z)$$

Uma função candidata para $\ell(\cdot)$ seria a norma quadrática $\ell(\varepsilon, \theta, t) = 0.5\varepsilon(t, \theta)^2$. Para $E_N(2\pi k/N, \theta), k = 0, 1, \dots, N-1$ a TDF de $\varepsilon(t, \theta)$ de N amostras, pela relação de Parseval, é possível aproximar a função de custo por:

$$V(\theta, Z) = \frac{1}{N} \sum_{t=1}^N \frac{1}{2} \varepsilon(t, \theta)^2 = \frac{1}{2N} \sum_{k=1}^{N-1} |E_N(2\pi k/N, \theta)|^2$$

Considerando $w(t, \theta) = G(q, \theta)u(t)$, conforme descrito no Teorema 2.1 de [1]:

$$W_N(\omega, \theta) = G(e^{j\omega}, \theta)U_N(\omega) + R_N(\omega)$$

Analogamente, para $s(t, \theta) = y(t) - w(t, \theta)$:

$$S_N(\omega, \theta) = Y_n(\omega) - G(e^{j\omega}, \theta)U_N(\omega) - R_N^*(\omega)$$

Sendo assim, para $\varepsilon(t, \theta) = H^{-1}(q, \theta)s(t, \theta)$:

$$E_N(\omega, \theta) = H^{-1}(e^{j\omega}, \theta)S_N(\omega, \theta) - \tilde{R}_N(\omega)$$

Dessa forma, $|E_N(2\pi k/N, \theta)|^2$ é encontrado como;

$$|E_N(2\pi k/N, \theta)|^2 = |H(e^{2\pi jk/N}, \theta)|^{-2} \cdot |Y_n(2\pi jk/N) - G(e^{2\pi jk/N}, \theta)U_N(2\pi jk/N)|^2 + \bar{R}_N$$

Sabendo que $\hat{G}_N = Y_N(\omega)/U_N(\omega)$, é possível reescrever a equação acima como:

$$|E_N(2\pi k/N, \theta)|^2 = Q_N(e^{2\pi jk/N}, \theta) \cdot |\hat{G}(2\pi jk/N) - G(e^{2\pi jk/N}, \theta)|^2 + \bar{R}_N$$

para $Q_N(\omega, \theta) = |U_N(\omega)|^2/|H_N(2\pi k/N, \theta)|^2$.

Substituindo a expressão acima na equação da função de custo $V(\theta, Z)$, é evidente que $Q_N(\omega, \theta)$ é o fator de ponderação da média ponderada. Esse peso é então determinada pelo inverso da variância $\alpha_k = \frac{|U_N(2\pi k/N)|^2}{\Phi_v(2\pi k/N)}$, ou seja, o inverso da relação sinal ruído.

Para N grande, é possível aproximar o somatório por uma integral de tal forma que:

$$V(\theta, Z) = \frac{1}{2\pi} \int_{-\pi}^{\pi} \frac{1}{2} Q_N(\omega, \theta) \cdot |\hat{G}(e^{j\omega}) - G(e^{j\omega}, \theta)|^2 d\omega$$

Para solucionar o problema de iteração sobre a função de custo para encontrar um mínimo global, pode-se empregar regressão linear. É importante destacar que esse método não é válido para preditores não lineares, como ARMAX (apresentado na Atividade 04).

Regressão linear com mínimos quadrados

O preditor é escrito como:

$$\hat{y}(t|\theta) = \varphi^T \theta + \mu(t)$$

para $\varphi(t) = [-y(t-1) \ -y(t-2)\dots \ -y(t-n_a) \ u(t-1) \ u(t-2)\dots \ u(t-n_b)]^T$ o vetor de regressores e $\mu(t)$ um termo conhecido dependente dos dados em instantes anteriores.

Se considerarmos $\mu(t) = 0$, o erro de predição é dado por:

$$\varepsilon(t) = y(t) - \varphi^T \theta$$

Então, para $L(q) = 1$ e $\ell = 0.5\varepsilon^2$, a função de custo é:

$$V(\theta, Z) = \frac{1}{N} \sum_{t=1}^N \frac{1}{2} (y(t) - \varphi^T \theta)^2$$

Derivando a função de custo analiticamente, é possível comprovar que o mínimo local é dado pelo vetor de parâmetros:

$$\hat{\theta}_{LS} = \arg \min V(\theta, Z) = \left[\sum_{t=1}^N \varphi(t) \varphi^T(t) \right]^{-1} \sum_{t=1}^N \varphi(t) y(t) = P(t) \sum_{t=1}^N \varphi(t) y(t)$$

na condição que a inversa $P(t)$ existe.

Caso a processo identificado seja variante no tempo, é possível ponderar as amostras mais recentes na função de custo. Sendo assim, é necessário incluir o fator multiplicativo peso a seguir:

$$V(\theta, Z) = \frac{1}{N} \sum_{t=1}^N \alpha(t) (y(t) - \varphi^T \theta)^2$$

Análise da polarização da estimativa

Se considerarmos que há um ruído branco de média nula $e(t)$ na saída $y(t)$, é possível considerar esse erro na modelagem ao reescrever a equação de estimação como:

$$\hat{y}(t) = \varphi^T(t) \theta_0 + e(t)$$

Logo, encontra-se que:

$$\hat{\theta}_0 = P(t) \sum_{t=1}^N \varphi(t) [y(t) + e(t)]$$

Sendo assim, o erro entre a estimativa $\hat{\theta}$ não considerando o erro na modelagem e θ_0 considerando o erro na modelagem é dado por:

$$\tilde{\theta} = \hat{\theta} - \theta_0 = P(t) \sum_{t=1}^N \varphi(t) e(t)$$

A esperança desse erro é então dado por:

$$E(\tilde{\theta}) = P(t) \sum_{t=1}^N \varphi(t) E(e(t)) = 0$$

Logo, é possível concluir que a estimativa por mínimos quadrados para modelos com ruído branco na medição não possui polarização. Entretanto, se $e(t)$ não for um ruído branco, não é possível garantir a convergência do algoritmo de recursão dos mínimos quadrados. Nesse caso, é possível caracterizar o ruído como:

$$e(t) = \kappa(q) e^*(t)$$

para $\kappa(q)$ um filtro linear $e^*(t)$ um ruído branco. Reescrevendo o modelo como:

$$A(q) \kappa^{-1}(q) y(t) = B(q) \kappa^{-1}(q) u(t) + e^*(t)$$

para $\kappa^{-1}(q) = L(q)$ na notação da seção anterior, é possível garantir que não irá existir polarização sobre o vetor de parâmetros estimados.

Análise probabilística

É possível estimar θ também a partir de uma análise probabilística. Dessa forma, a modelagem é adequada independentemente da formulação dos dados como processos estocásticos.

Supondo que as observações do sistema são uma variável aleatória y cuja função densidade de probabilidade (*probability density function* - PDF) é:

$$P(y \in A) = \int_{x \in A} f_y(\theta, x) dx$$

Logo, a estimativa $\hat{\theta}$ pode ser escolhido como o valor que maximiza a probabilidade do evento observado y , ou seja:

$$\hat{\theta}_{ML} = \arg \max_{\theta} f_y(\theta, y_*)$$

Essa função é determinística para θ a partir do momento que o valor de y_* é conhecido. Portanto, ela é nomeada função de probabilidade (*likelihood function*).

Por exemplo, considerando y uma variável aleatória independente com distribuição normal tal que $y \in N(\theta_0, \gamma_i)$, a PDF é dada por:

$$f_y(\theta, x) = \prod_{i=1}^N \frac{1}{\sqrt{2\pi\lambda_i}} \exp \left[-\frac{(x_i - \theta)^2}{2\lambda_i} \right]$$

O máximo global dessa função equivale a encontrar o máximo global de $\log f_y$. Dessa forma, a estimativa $\hat{\theta}_{ML}$ é:

$$\hat{\theta}_{ML} = \arg \max_{\theta} \log f_y(\theta, y_*) = \frac{\sum_{i=1}^N y(i)(\lambda_i)^{-1}}{\sum_{i=1}^N (\lambda_i)^{-1}}$$

Para modelos dinâmicos, no entanto, o sinal $y(t)$ é dado por:

$$y(t) = g(t, Z^{t-1}, \theta) + \varepsilon(t, \theta)$$

Como $\varepsilon(t, \theta)$ é um ruído com PDF $f_e(x, t, \theta)$ conhecida, é possível afirmar que:

$$\bar{f}_y(\theta, y) = \prod_{t=1}^N f_e(\varepsilon(t, \theta), t, \theta) = \prod_{t=1}^N f_e(y(t) - g(t, Z^{t-1}, \theta), t, \theta)$$

Logo, maximizar a função acima equivale a maximizar:

$$\frac{1}{N} \log \bar{f}_y(\theta, y) = \frac{1}{N} \sum_{t=1}^N \log f_e(\varepsilon(t, \theta), t, \theta)$$

Se definirmos $\ell(\varepsilon, \theta, t) = -\log f_e(\varepsilon, \theta, t)$, então nós podemos escrever:

$$\hat{\theta}_{ML} = \arg \min_{\theta} \sum_{t=1}^N \ell(\varepsilon(t, \theta), t, \theta)$$

Análise de correlação do erro do preditor com dados anteriores

Idealmente, o erro de predição $\varepsilon(t, \theta)$ deveria ser independente dos dados em instantes anteriores Z^{t-1} . Se essa correlação não for nula, então existe algum dado em $y(t)$ que não está sendo previsto pelo modelo proposto $\hat{y}(t|\theta)$.

Entretanto, é inviável testar se essa condição é verdadeira para o conjunto de dados coletados se N for grande ou $\varepsilon(t, \theta)$ uma transformação não linear. Dessa forma, é preferível selecionar uma sequência finita $\zeta(t)$ de Z^{t-1} e garantir que essa sequência é descorrelacionada de $\varepsilon(t, \theta)$. Matematicamente:

$$\frac{1}{N} \sum_{t=1}^N \zeta(t) \varepsilon(t, \theta) = 0$$

A melhor escolha para $\zeta(t)$ depende das propriedades do sistema. Estritamente, é necessário que as variáveis no vetor $\zeta(t)$ sejam descorrelacionadas do ruído $v(t) = H(q)e(t)$ adicionado na saída do modelo.

A solução pelo método dos mínimos quadrados é dada por:

$$\hat{\theta}_{LS} = \text{sol} \left\{ \frac{1}{N} \sum_{t=1}^N \varphi(t) [y(t) - \varphi^T(t)\theta] = 0 \right\}$$

Sendo assim, é possível adotarmos as variáveis $\zeta(t)$ (nomeadas variáveis instrumentais, do inglês *instrumental variables* - IV), de tal forma que:

$$\hat{\theta}_{LS}^{IV} = \text{sol} \left\{ \frac{1}{N} \sum_{t=1}^N \zeta(t) [y(t) - \varphi^T(t)\theta] = 0 \right\}$$

Assim, o vetor de parâmetros estimados $\hat{\theta}$ é encontrado por:

$$\hat{\theta}_{LS}^{IV} = \left[\sum_{t=1}^N \zeta(t) \varphi^T(t) \right]^{-1} \sum_{t=1}^N \zeta(t) y(t) = P(t) \sum_{t=1}^N \zeta(t) y(t)$$

É evidente que $P(t)$ deve ser inversível e que a esperança $E[\zeta(t)v(t)] = 0$ para que a estimativa $\hat{\theta}_{LS}^{IV}$ não seja polarizada. Para um modelo ARX, tem-se que:

$$y(t) + a_1 y(t-1) + \dots + a_{n_a} y(t-n_a) = b_1 u(t-1) + \dots + b_{n_b} u(t-n_b) + v(t)$$

Uma sugestão para a construção do vetor $\zeta(t)$ seria incluir os elementos não influenciados por $v(t)$, ou seja:

$$\zeta(t) = K(q) [-x(t-1) \ -x(t-2) \dots \ -x(t-n_a) \ u(t-1) \ u(t-2) \dots \ u(t-n_b)]^T$$

para $K(q)$ um filtro linear e $x(t)$ dependente da entrada a partir da modelagem pela equação:

$$N(q)x(t) = M(q)u(t), \text{ para } N(q) = 1 + n_1 q^{-1} + \dots + n_{n_n} q^{-n_n} \text{ e } M(q) = m_0 + m_1 q^{-1} + \dots + m_{n_m} q^{-n_m}$$

Logo, como $\zeta(t)$ pode ser gerada em malha aberta e depende apenas de valores anteriores de $u(t)$, as variáveis instrumentais independem do ruído $v(t)$.

Uma solução simplificada para encontrar os polinômios seria inicialmente aplicar o método de mínimos quadrados sobre o modelo ARMA completo (com o termo $v(t)$), e, em seguida, sobre os polinômios $N(q)$ e $M(q)$. O vetor de variáveis instrumentais é, então, facilmente encontradas adotando $K(q) = 1$.

Desenvolvimento

Nessa atividade, é proposta a estimação de uma função de transferência $G(z)$ conhecida. Essa planta foi simulada para uma entrada PRBS e um ruído branco $e(t)$ de média nula e variância unitária somado na saída.

O processo ARMA que define $y(t)$ é dado por:

$$y(t) - 1.5y(t-1) + 0.7y(t-2) = u(t-1) + 0.5u(t-2) + e(t)$$

Assim, é evidente que:

$$G_0(q) = \frac{z^{-1} + 0.5z^{-2}}{1 - 1.5z^{-1} + 0.7z^{-2}} = \frac{b_1z^{-1} + b_2z^{-2}}{1 + a_1z^{-1} + a_2z^{-2}}$$

A letra A do exercício proposto corresponde à Atividade 06. Dessa forma, nesse relatório, serão realizadas as letras B e C. Dessa forma, serão estimados os parâmetros via mínimos quadrados diretamente do vetor de regressão $\varphi(t)$. Em seguida, será utilizado o método das variáveis instrumentais sobre o vetor $\zeta(t)$. Os resultados serão comparados para duas condições de amostragem $N = 100$ e $N = 400$, três escolhas de $K(q)$, $M(q)$ e $N(q)$ e diferentes ordens do vetor de regressão $\varphi(t)$ ($n_a = n_b = 2$ e $n_a = n_b = 3$).

Resultados e discussão

Para o método dos mínimos quadrados, foi adotado o vetor de parâmetros $\theta = [a_1 \ a_2 \ b_1 \ b_2]^T$ e $\varphi(t) = [-y(t-1) \ -y(t-2) \ u(t-1) \ u(t-2)]^T$. Observando a função de transferência, é evidente que $\theta_0 = [-1.5 \ , \ 0.7 \ , \ 1.0 \ , \ 0.5]^T$

O resultado dos parâmetros estimados para $u(t)$ um sinal PRBS e $e(t) \in N(0, 1)$, pelo método dos mínimos quadrados comum e para $N = 100$ é:

```
N = 100; myLS
```

```
Warning: The PRBS signal delivered is the 100 first values of a full sequence of length 127.
theta_LS = 1x4
    -1.5433    0.7759    1.0800    0.5326
```

Observando o resultado acima, é evidente que o resultado diverge do vetor esperado θ_0 . Essa conclusão é justificada pela correlação não nula entre o vetor de regressão $\varphi(t)$ e o ruído $e(t)$. Para dispensar a modelagem do ruído e garantir uma boa estimação dos parâmetros do sistema, é possível empregar variáveis instrumentais.

Para $K(q) = 1$, $N(q) = 1$ e $M(q) = q^{-2}$, tem-se que $x(t) = u(t-2)$ e que o vetor $\zeta(t) = [-x(t-1) \ -x(t-2) \ u(t-1) \ u(t-2)]^T$. Sendo assim, é possível estimar os parâmetros estimados $\hat{\theta}$ como:

```
myIV_c1
```

```
theta_IV_c1 = 1x4
    -1.7205    1.1890    1.0126    0.2072
```

Esse resultado se aproxima mais lentamente do vetor esperado θ_0 do que o experimento anterior. Esse resultado pode ser otimizado com melhores escolhas de $K(q)$, $M(q)$ e $N(q)$.

Empregando $K(q) = 1$ e $M(q) = A(q)$ e $N(q) = B(q)$, para $A(q)$ e $B(q)$ os polinômios estimados pelo mínimos quadrados (variável `theta_LS`), é possível encontrar os valores estimados:

```
myIV_c2
```

```
theta_IV_c2 = 1x4
    -1.5938    0.8439    1.0796    0.4706
```

Comparando as variáveis `theta_LS` e `theta_IV_c2`, é evidente que a primeira está mais próxima dos parâmetros reais θ_0 .

Considerando mais uma otimização, o último modelo define $K(q) = 1/(1 - 1.5q^{-1} + 0.7q^{-2})$, $N(q) = 1 - 1.5q^{-1} + 0.7q^{-2}$ e $M(q) = 1 + 0.5q^{-2}$. Esse é um caso especial considerando que $A(q)$

e $B(q)$ são estimativas perfeitas dos polinômios de $G_0(q)$. O resultado obtido para o vetor de parâmetros estimados é:

```
myIV_c3
```

```
theta_IV_c3 = 1x4  
    -1.6256    0.8665    1.1805    0.2358
```

Assim como do experimento anterior, é evidente que o modelo para método dos mínimos quadrados comum produz as estimativas mais próximas de θ_0 . Será analisado se essa observação se mantém para maior número de amostras

Aumentaremos N para 400 amostras. Os resultados para os 4 experimentos, em sequência, são:

```
N = 400; myLS
```

```
Warning: The PRBS signal delivered is the 400 first values of a full sequence of length 511.  
theta_LS = 1x4  
    -1.4986    0.7131    1.0533    0.5010
```

```
myIV_c1
```

```
theta_IV_c1 = 1x4  
    -1.4282    0.6171    1.0556    0.5705
```

```
myIV_c2
```

```
theta_IV_c2 = 1x4  
    -1.5111    0.7269    1.0524    0.4880
```

```
myIV_c3
```

```
theta_IV_c3 = 1x4  
    -1.5509    0.7587    1.0856    0.3199
```

Comparando os resultados acima, é evidente que ambos os experimentos para método dos mínimos quadrados comum e $K(q) = 1$ e $M(q) = A(q)$ e $N(q) = B(q)$ são os mais próximos do vetor θ_0 . Analogamente, comparando os resultados para $N = 400$ e $N = 100$, é claro que, com o aumento do número de amostras, há um menor erro de predição.

No caso apresentado, ambas as abordagens (com e sem variáveis de instrumentação) são adequadas para encontrar as estimativas. Uma solução melhor para o conjunto de variáveis instrumentais pode ser obtida procurando um novo conjunto de $K(q)$, $M(q)$ e $N(q)$.

Analisando os resultados obtidos, é possível destacar que o as variáveis instrumentais (diferentemente do mínimos quadrados comum) dispensa a modelagem do ruído. Essa característica é adequada para situações em que não há interesse em concentrar esforços para modelá-lo.

Referências bibliográficas

[1] L. LJUNG. **System Identification: Theory for the User**. Pearson, 1998. 2nd edition, ISBN 9788131744956.