


Estimação e identificação de sistemas

Atividade 1 a 4



Débora Oliveira

14 de Outubro de 2021





Sumário



01 **Estimação de parâmetros**


Identificação pelo método dos mínimos quadrados.

02/03 **Sistemas lineares variantes no tempo**

Análise em frequência e covariância.

04 **Equação de predição**

Vetores de regressão para múltiplos modelos.



01

Estimação de parâmetros

Identificação pelo método dos mínimos quadrados.



Métodos dos mínimos quadrados



Método de estimação que propõe encontrar o menor erro entre o **sistema discreto** estimado e real.



Processo estimado

$$\hat{y}(t|\theta) = -a_1 y(t-1) - \dots - a_n y(t-n) + b_1 u(t-1) + \dots + b_m u(t-m) = \varphi^T(t)\theta$$



Função de custo

$$V(\theta, t) = \frac{1}{2} \sum_{k=1}^t (y(k) - \varphi^T(k)\theta)^2$$

$$\partial V(\hat{\theta}, t) / \partial \theta = 0 \Rightarrow \hat{\theta} = \left[\sum_{k=1}^t \varphi(k) \varphi^T(k) \right]^{-1} \sum_{k=1}^t \varphi(k) y(k) = P(t) \sum_{k=1}^t \varphi(k) y(k)$$

Métodos dos mínimos quadrados





Fig. 1: Parâmetros a e b da função de transferência estimados para os dados coletados a partir dos modelos simulados 1 e 2.

$$\delta_1 : y(t) = 0.8y(t-1) + u(t-1) + e(t-1)$$

$$\delta_2 : y(t) = 0.8y(t-1) + u(t-1) + e(t) - 0.8e(t-1)$$

Ruído gaussiano com média nula e variância unitária.



Modelo estimado

$$H(q^{-1}) = \frac{bq^{-1}}{1+aq^{-1}}$$



Métodos dos mínimos quadrados




Σ Covariância do erro

$$\begin{aligned} R = E(\tilde{\theta}\tilde{\theta}^T) &= E\left[P(t) \sum_{t,s=1}^N \varphi(t) [e(t) - 0.8e(t-1)] [e(s) - 0.8e(s-1)] \varphi^T(s) P(s)\right] \\ &= P(t) \sum_{t,s=1}^N \varphi(t) \varphi^T(s) P(s) \left(E[e(t)e(s)] - 0.8E[e(t)e(s-1)] - 0.8E[e(t-1)e(s)] + 0.64E[e(t-1)e(s-1)] \right) \\ &= P(t) \lambda^2 [1.64 - 1.6(N-1)] \sum_{t,s=1}^N \varphi(t) \varphi^T(s) P(s) = P(t) \lambda^2 (3.24 - 1.6N) \end{aligned}$$

$$\lim_{N \rightarrow \infty} R = M^{-1} \lambda^2 (3.24N^{-1} - 1.6)$$

Covariância da entrada



02/03

Sistemas lineares variantes no tempo

Análise em frequência e covariância.



Periodograma



Periodograma ou **DFT** (*Discrete Fourier Transform*) pondera cada componente de frequência em um sinal para manutenção do teorema de Parseval.

$$U_N(\omega) = \frac{1}{\sqrt{N}} \sum_{t=1}^N u(t) e^{-j\omega t}$$



Relação de Parseval

$$\sum_{k=1}^N |U_N(2\pi k/N)|^2 = \sum_{t=1}^N u^2(t)$$



Espectro de um sinal

$$\Phi_s(\omega) = \sum_{\tau=-\infty}^{\infty} R_s(\tau) e^{-j\tau\omega}$$

$$s(t) = G(q)u(t) + H(q)v(t)$$



$$v(t) = H(q)e(t)$$

$$\Phi_v(\omega) = \lambda |H(e^{j\omega})|^2$$



Periodograma




Fig. 2: Periodograma e espectro suavizado para a função $v(t)$

$$v(t) = e(t) + 0.5e(t-1) + 1.5v(t-1) + 0.7v(t-2)$$

Ruído gaussiano com média nula e variância unitária.

Podemos encontrar a função de transferência a partir do espectro?



Exemplo

$$\Phi_v(\omega) = \frac{1.25 + \cos \omega}{1.64 + 1.6 \cos \omega}$$



$$v(t) + a_1 v(t-1) + \dots + a_{n_a} v(t-n_a) = c_0 e(t) + c_1 e(t-1) + \dots + c_{n_c} e(t-n_c)$$

$$H(e^{j\omega}) = \frac{c_1 e^{j\omega} + c_0}{a_1 e^{j\omega} + a_0}$$

$$|H(e^{j\omega})|^2$$

$$\begin{cases} |C(e^{j\omega})|^2 = (c_1)^2 + (c_0)^2 + 2c_1 c_0 \cos \omega & = 1.25\lambda^{-1} + \lambda^{-1} \cos \omega \\ |A(e^{j\omega})|^2 = (a_1)^2 + (a_0)^2 + 2a_1 a_0 \cos \omega & = 1.64 + 1.6 \cos \omega \end{cases}$$

Numerador

$$(a_0)^4 - 1.64(a_0)^2 + 0.64 = 0 \Rightarrow [a_0, a_1] = (0.8, 1)$$

Denominador

$$(c_0)^4 - 1.25\lambda^{-1}(c_0)^2 + 0.25\lambda^{-2} = 0 \Rightarrow [c_0, c_1] = (0.5\lambda^{-0.5}, \lambda^{-0.5})$$

$$H(z) = \frac{V(z)}{E(z)} = \frac{(\lambda^{-0.5})z + 0.5\lambda^{-0.5}}{z + 0.8}$$

$$v(t) = \lambda^{-0.5} e(t) + 0.5\lambda^{-0.5} e(t-1) - 0.8v(t-1)$$

$$H(z) = \frac{V(z)}{E(z)} = \frac{(\lambda^{-0.5})z + 0.5\lambda^{-0.5}}{z + 0.8} = \lambda^{-0.5} \left[\frac{1 + 0.5z^{-1}}{1 + 0.8z^{-1}} \right]$$



$$y(t) = -a_1 y(t-1) - a_2 y(t-2) + e(t) + c_1 e(t-1) + c_2 e(t-2)$$

$$R_{ey}(0) = E(e_t y_t) = -a_1 E(e_t y_{t-1}) - a_2 E(e_t y_{t-2}) + E(e_t e_t) + c_1 E(e_t e_{t-1}) + c_2 E(e_t e_{t-2})$$

$$R_{ey}(1) = E(e_{t-1} y_t) = -a_1 E(e_{t-1} y_{t-1}) - a_2 E(e_{t-1} y_{t-2}) + E(e_{t-1} e_t) + c_1 E(e_{t-1} e_{t-1}) + c_2 E(e_{t-1} e_{t-2})$$

$$R_{ey}(2) = E(e_{t-2} y_t) = -a_1 E(e_{t-2} y_{t-1}) - a_2 E(e_{t-2} y_{t-2}) + E(e_{t-2} e_t) + c_1 E(e_{t-2} e_{t-1}) + c_2 E(e_{t-2} e_{t-2})$$

$$R_y(0) = E(y_t y_t) = -a_1 E(y_t y_{t-1}) - a_2 E(y_t y_{t-2}) + E(y_t e_t) + c_1 E(y_t e_{t-1}) + c_2 E(y_t e_{t-2})$$

$$R_y(1) = E(y_{t-1} y_t) = -a_1 E(y_{t-1} y_{t-1}) - a_2 E(y_{t-1} y_{t-2}) + E(y_{t-1} e_t) + c_1 E(y_{t-1} e_{t-1}) + c_2 E(y_{t-1} e_{t-2})$$

$$R_y(2) = E(y_{t-2} y_t) = -a_1 E(y_{t-2} y_{t-1}) - a_2 E(y_{t-2} y_{t-2}) + E(y_{t-2} e_t) + c_1 E(y_{t-2} e_{t-1}) + c_2 E(y_{t-2} e_{t-2})$$

$$E(e_i y_k) = 0, \forall i > k \quad \begin{matrix} \nabla \\ \nabla \end{matrix} \quad \begin{matrix} E(e_i e_k) = 0, \forall i \neq k \\ E(e_i e_k) = \lambda, \forall i = k \end{matrix}$$

$$R_{ey}(0) = E(e_t e_t) = \lambda$$

$$R_{ey}(1) = -a_1 R_{ey}(0) + c_1 E(e_t e_t) = \lambda(-a_1 + c_1)$$

$$R_{ey}(2) = -a_1 R_{ey}(1) - a_2 R_{ey}(0) + c_2 E(e_t e_t) = \lambda[(a_1)^2 - a_1 c_1 - a_2 + c_2]$$

$$R_y(0) = \gamma_0 = -a_1 \gamma_1 - a_2 \gamma_2 + k_0$$

$$R_y(1) = \gamma_1 = -a_1 \gamma_0 - a_2 \gamma_1 + k_1$$

$$R_y(2) = \gamma_2 = -a_1 \gamma_1 - a_2 \gamma_0 + k_2$$



$$R_y(0) = \frac{(1+a_2) \left[1 + (c_1)^2 + (c_2)^2 \right] - 2a_1 c_1 (1+c_2) - 2c_2 \left[a_2 - (a_1)^2 + (a_2)^2 \right]}{(1-a_2)(1-a_1+a_2)(1+a_1+a_2)}$$

Podemos encontrar a autocovariância não analiticamente?



$$R_v(\tau) = \frac{1}{2\pi} \int_{-\pi}^{\pi} \Phi_v(\omega) e^{j\omega\tau} d\omega = \frac{\lambda}{2\pi} \int_{-\pi}^{\pi} \left| \frac{C(e^{j\omega})}{A(e^{j\omega})} \right|^2 e^{j\omega\tau} d\omega = \frac{\lambda}{2\pi} \oint \frac{C(z)C(1/z)}{A(z)A(1/z)} z^{\tau-1} dz$$




$$\begin{aligned} A_k(z) &= a_0^k z^k + a_1 z^{k-1} + \dots + a_k^k \\ A^*(z) &= z^n A(z^{-1}) = a_0 + a_1 z + \dots + a^n z^n \end{aligned}$$



$$\begin{aligned} A_{k-1}(z) &= z^{-1} [A_k(z) - \alpha_k A_k^*(z)], \alpha_k = a_k^k / a_0^k \\ C_{k-1}(z) &= z^{-1} [c_k(z) - \beta_k C_k^*(z)], \beta_k = c_k^k / a_0^k \end{aligned}$$



$$R_v(0) = \frac{1}{a_0^k} \sum_{k=0}^n \frac{(b_i^i)^2}{a_0^i}$$



04

Equação de predição

Vetores de regressão para
múltiplos modelos.

Preditor de um passo

Modelo Geral

$$A(q)y(t) = \frac{B(q)}{F(q)}u(t) + \frac{C(q)}{D(q)}e(t)$$



Preditor Geral

$$C(q)F(q)\hat{y}(t|\theta) = D(q)B(q)u(t) + F(q)[C(q) - D(q)A(q)]y(t)$$



Modelo ARX



Modelo

$$y(t) + a_1 y(t-1) + \dots + a_{n_a} y(t-n_a) = b_1 u(t-1) + \dots + b_{n_b} u(t-n_b) + e(t)$$



Regressão

$$\theta = [a_1 \ a_2 \ \dots \ a_{n_a} \ b_1 \ b_2 \ \dots \ b_{n_b}]$$

$$\varphi(t) = [-y(t-1) \ \dots \ y(t-n_a) \ u(t-1) \ \dots \ u(t-n_b)]$$



Preditor

$$\hat{y}(t|\theta) = B(q)u(t) + [1 - A(q)]y(t) = \theta^T \varphi(t)$$

Preditor de um passo

Modelo Geral

$$A(q)y(t) = \frac{B(q)}{F(q)}u(t) + \frac{C(q)}{D(q)}e(t)$$



Preditor Geral

$$C(q)F(q)\hat{y}(t|\theta) = D(q)B(q)u(t) + F(q)[C(q) - D(q)A(q)]y(t)$$



Modelo ARMAX



Modelo

$$y(t) + a_1 y(t-1) + \dots + a_{n_a} y(t-n_a) = b_1 u(t-1) + \dots + b_{n_b} u(t-n_b) + e(t) + c_1 e(t-1) + \dots + c_{n_c} e(t-n_c)$$



Regressão

$$\theta = [a_1 \ a_2 \ \dots \ a_{n_a} \ b_1 \ b_2 \ \dots \ b_{n_b} \ c_1 \ c_2 \ \dots \ c_{n_c}]$$

$$\varphi(t, \theta) = [-y(t-1) \ \dots \ y(t-n_a) \ u(t-1) \ \dots \ u(t-n_b) \ \varepsilon(t-1, \theta) \ \dots \ \varepsilon(t-n_c, \theta)]$$



Preditor

$$C(q)\hat{y}(t|\theta) = B(q)u(t) + [C(q) - A(q)]y(t)$$

$$\hat{y}(t|\theta) = B(q)u(t) + [1 - A(q)]y(t) + [C(q) - 1][y(t) - \hat{y}(t|\theta)]$$

Preditor de um passo

Modelo Geral

$$A(q)y(t) = \frac{B(q)}{F(q)}u(t) + \frac{C(q)}{D(q)}e(t)$$



Preditor Geral

$$C(q)F(q)\hat{y}(t|\theta) = D(q)B(q)u(t) + F(q)[C(q) - D(q)A(q)]y(t)$$



Modelo Output-error



Modelo

$$y(t) = \frac{B(q)}{F(q)}u(t) + e(t)$$



$$w(t) = [B(q)/F(q)]u(t)$$

$$w(t) + f_1 w(t-1) + \dots + f_{n_f} w(t-n_f) = b_1 u(t-1) + \dots + b_{n_b} u(t-n_b)$$



Regressão

$$\theta = [b_1 \ b_2 \ \dots \ b_{n_b} \ f_1 \ f_2 \ \dots \ f_{n_f}]$$

$$\varphi(t, \theta) = [u(t-1) \ \dots \ u(t-n_b) \ w(t-1, \theta) \ \dots \ w(t-n_f, \theta)]$$

Estimação e identificação de sistemas

Atividade 1 a 4



Débora Oliveira

14 de Outubro de 2021

